

AI AGENT · 실행 환경 설계 · 데이터 파이프라인

실패의 원인을 깊이 파고들어 해결하는 것을 좋아하는 개발자

각 프로젝트에서 마주한 문제, 해결을 위한 시도와 결과, 그에 따른 판단과 구현 과정을 담았습니다.

김재형

AI Application Developer · Backend Engineer

kkuldangi2@gmail.com · martinel2.github.io

LLM 워크스페이스의 AI 기능 전체를 맡아 RAG와 에이전트, 품질 평가 체계를 설계하고, AI 코딩 도구로 구현·검증했습니다.

정확도와 비용, 응답 시간의 트레이드오프를 평가로 확인한 뒤 서비스에 맞는 구현을 선택합니다.

RAG 근거 선택: 근거 충족률 66.25% → 91.25%, 잘못된 근거 20 → 0건

골든셋을 만들고 동일 후보·블라인드·두 모델 교차채점으로 조건을 통제된 오프라인 비교 평가를 거쳐 근거 선택 단계를 교체했습니다. 후보 수와 병렬 처리를 조정해 선택 시간 중앙값 9.090초 → 2.251초.

에이전트 실행 환경: 사용자 정의 Skill과 승인 기반 실행, 편집 품질 82.5% → 91.2%(114건 평가)

권한과 프롬프트 주입 검사는 코드가, 작업 지침과 수정안 생성은 AI가, 게시와 실제 반영은 사용자가 맡도록 책임을 나눴습니다. 사용자가 승인하기 전에는 문서를 바꾸지 않습니다.

데이터 파이프라인: PDF 변환 통과율 45.17% → 89.89%, 약품 변환 비용 예상 \$200 대비 \$11.18

본문·표·수식의 처리 경로를 나눠 문서를 검색과 답변에 쓸 수 있게 변환하고, 중복 제거와 Batch 변환으로 약 4만 4천 건을 예산 안에서 처리했습니다.

목차

시간이 없으시면 01·02·04를 먼저 보시면 됩니다. 표지의 세 가지가 각각 품질 평가, 에이전트 실행 환경, 데이터 파이프라인입니다.

FRUITION

01	RAG 근거 선택 - 충족률 66.25% → 91.25% 개선	p.6
02	에이전트 실행 환경 - 지침 작성·검증·승인 설계	p.12
03	작업 취소 - 저장한 변경의 역순 복구	p.18
04	PDF 변환 - 통과율 45.17% → 89.89% 개선	p.22
05	문서 병렬 분석 - 처리시간 73.8% 단축	p.26
06	에이전트 루프 - PR 16개 5일 병합	p.28

PILLTIP

07	의약품 정제 - 예상 \$200 대비 \$11.18로 변환	p.35
08	복약 챗봇 - 건강 프로필의 외부 전송 제외	p.40

MORE

09	코드 밖에서도 이어지는 경험	p.43
	Rhwp · HWPX 저장 오류 수정 APPTIVE · 백엔드 멘토링 백준 945일 연속 문제 해결	
10	프로젝트 회고	p.44

Fruition

올린 문서를 LLM이 Wiki로 정리하고, RAG로 원문 근거를 찾아 답하거나 자연어로 문서를 편집하는 AI 워크스페이스입니다. 지금은 AWS EKS에 배포해 QA를 진행하고 있습니다.

시작 계기

팀원이 겪던 문서 관리의 불편함을 디자인 싱킹으로 구체화하며 시작했습니다. 문서를 저장만 해 두고 정작 필요할 때 찾지 못하는 불편을 없애는 게 목표였습니다.

GitHub · AI 분리 저장소 ↗

팀 구성과 내 역할

MY ROLE

AI

PDF 변환, Wiki 생성, RAG 검색·근거 답변, 문서 편집 Agent 등 AI 기능 전체

01 AI 기능 전체 리드

PDF문서 변환, Wiki 생성·정리, 검색·근거 답변, 문서 편집 Agent 등 AI 기능 전반의 설계·평가를 리드하고, 구현은 AI 코딩 도구로 진행했습니다.

02 MSA 설계 기여

처음 초안은 기능별로 서비스를 나눴습니다. 그런데 그렇게 나누면 DB에 걸리는 부하는 그대로고, 서비스를 거치는 호출만 늘어 분산하는 의미가 없었습니다. 그래서 데이터 소유권을 기준으로 나누자고 제안했고, 팀원·멘토와 서비스 경계와 통신 방식을 논의해 최종 구조를 함께 완성했습니다.

백엔드 1명

Spring 기반 백엔드 전체

프론트엔드·DevOps 1명

프론트엔드 전체, MSA 기반 AWS 배포

디자인

외주 디자이너

멘토 3명

Gen AI 품질·평가 / 백엔드 전반 / 마일스톤·MSA 설계·문서화

담당 기능과 서비스 화면



문서 편집·AI 어시스턴트
요청을 해석하고 수정안을 생성·검증하는 AI 기능을 리드했습니다. 편집기와 어시스턴트 UI는 팀 구현입니다.



Wiki 생성·검색
문서를 지식으로 정리하고 연결해 질문에 맞는 근거를 찾는 AI 기능을 리드했습니다. 그래프와 검색 UI는 팀 구현입니다.

Architecture

시스템 아키텍처

브라우저는 Spring Boot API를 통해 데이터와 AI Service을 사용합니다.

기술	구현
Next.js	문서 · Wiki · Chat · Agent UI
Spring Boot	인증 · 권한 · 워크스페이스 · 상태
FastAPI	Ingest · Query · Lint · 문서 편집 Agent
PostgreSQL	관계 · 버전 · 작업 상태
MinIO	원본 · Markdown · artifact

14

서비스 역할 구분

AI 기능 전체를 리드했고 프론트엔드·백엔드는 팀원이 담당했습니다. MSA는 제 초기 설계를 바탕으로 팀원·멘토와 논의해 완성했습니다.

```

graph LR
    User[사용자  
문서를 정리하고 원하는 정보를 문서에서 찾기 위해 질문하는 사람]
    Oauth[Oauth Provider  
(Google/Naver/Kakao)]
    LLM[LLM Provider  
[ Open API / Claude API / Gemini API ]]
    Email[이메일 서비스 (SMTP)  
인증 메일 발송]
    Web[웹 검색 (Tavily)  
원문의 내용만으로 답변이 어려운 경우 웹 검색을 통한 답변 보강]
    Fruition[Fruition  
규칙 기반 문서 생성·정리 업무를 돕는 AI Agent 워크스페이스]

    User -.->|소셜 계정으로  
로그인 시 인증| Oauth
    User -.->|로그인(이메일/소셜) 후 이용| Fruition
    Fruition -->|AI 작업 요청| LLM
    Fruition -->|인증 메일 발송| Email
    Fruition -.->|답변 보강을 웹 검색  
(기본 꺼짐)| Web
  
```

The diagram illustrates the architecture of the 'Fruition - AI Agent 워크스페이스'. It is divided into several main components and their interactions:

- Frontend (Next.js - TypeScript)**: Interacts with the Backend via REST / SSE (JWT Bearer).
- Backend (Spring Boot - Java)**: The central hub that manages data and coordinates the AI pipeline.
 - Stores **메타데이터-관계 저장** (Metadata-Relationship Storage) in **AppDB PostgreSQL**.
 - Stores **원본 파일 저장** (Original File Storage) in **Object Storage MinIO(S3대용)**.
 - Stores **Wiki-embedding 저장** (Wiki-embedding Storage) in **Object Storage MinIO(S3대용)**.
 - Stores **원본 원가-산출물 저장** (Original Cost-Output Storage) in **Object Storage MinIO(S3대용)**.
 - Stores **변환 결과 전달 예정** (Conversion Result Delivery Pending) in **PDF Converter**.
 - Stores **외부 LLM 작업 요청** (External LLM Work Request) in **LLM Provider**.
- AI Pipeline (FastAPI - Python - LangGraph)**: Receives **진행-결과 callback** (Progress-Result Callback) from the Backend and manages the AI workflow.
- Data Providers**:
 - DAuth Provider (Google/NaVer/Kakao)**: Provides authentication for users.
 - 이메일 서비스 (SMTP) 인증 메일 발송** (Email Service (SMTP) Authentication Email Sending): Sends authentication emails.
 - LLM Provider [OpenAI API / Claude API / Gemini API]**: Provides the Large Language Model services.
 - 웹 검색 (Tavily) 웹 페이지 통한 답변 보장 (기본 제공)** (Web Search (Tavily) Answer Guarantee via Web Pages (Basic Provision)): Provides web search capabilities.
- User Interaction**:
 - 사용자** (User) interacts with the Frontend via **HTTPS**.
 - 문서를 정리하고 원하는 정보를 문서에서 찾기 위해 질문하는 사람** (Person who organizes documents and asks questions to find desired information in documents) is the primary use case.
 - 소셜 계정으로 로그인 시 인증** (Authentication when logging in with social account) is handled by the DAuth Provider.

위는 전체 시스템, 아래는 Fruition 내부 구성입니다. 제 담당은
llmPipeline(FastAPI·Python·LangGraph)을 중심으로 한 AI 기능이며,
프론트엔드·백엔드와 AWS 배포는 팀원이 담당했습니다.

RAG 근거 선택 - 충족률 66.25% → 91.25% 개선과 Jev 최적화로 처리시간 75% 단축

Jev는 정해진 선택지 중에서만 답을 고르는 판단 전용 모델입니다. 요청 라우팅에 먼저 써 보니, 같은 선택지를 준 기존 JSON 방식 77/98건·GPT-5-nano 63/98건보다 높은 81/98건을 맞혔고 판단도 빨랐습니다. 그래서 RAG의 답변 근거 선택에도 적용해 근거 충족률을 66.25%에서 91.25%로 높였습니다. 늘어난 시간은 후보 수와 병렬 처리를 조정해 줄였습니다.

2026.09

Jev 1.13.0

BGE-M3

BM25

RAG

품질 평가

배경

기존 검색은 답변에 필요한 근거를 놓치거나, 답이 없는 질문에도 근거를 붙였습니다. 잘못된 답변으로 이어질 수 있었습니다. 어디서 빠지는지 따라가 보니 정답 근거는 처음 후보에 모두 있었습니다. 그런데 검사 대상을 앞 8개 페이지로 제한하는 단계에서 90문항 중 76문항의 근거가 빠지고 있었습니다. 후보에서 필요한 근거를 고르고, 없으면 없다고 말하는 단계가 필요했습니다. 검색은 의미·키워드 검색과 Wiki 그래프 탐색으로 원문 근거를 모으는 고정 파이프라인으로 두고, 답변과 근거·관련 페이지·탐색 경로를 나눠 보여주도록 설계했습니다. 검색 전략을 스스로 세우는 Query Agent는 보류했습니다. 한 질문이 여러 검색 계획과 중간 결과에 따른 재계획을 요구할 때 에이전트를 늘리기로 기준을 정했습니다. 그 전까지는 고정 파이프라인이 더 적은 호출로 같은 근거를 모으고, 실패 지점도 추적하기 쉽다고 봤습니다.

근거 충족률(Golden set을 통한 LLM 평가)

66.25% → 91.25%

Jev 근거 선택 시간

**중앙값
9.090초 → 2.251초**

답 없는 질문 20건에 대한 근거 반환

20건 → 0건

실험과 개선 과정

1 요청 분류 성능 비교와 RAG 적용 결정

문제 상황

질문을 문서 편집으로 분류하는 등, 요청과 다른 작업으로 이어지는 문제가 있었습니다. 작업 종류와 부가 조건을 더 정확하고 빠르게 고를 방법이 필요했습니다.

시도와 결과

9/14에 출시된 선택형 판단 모델 Jev를, 사용자 요청을 질문·문서 편집·문서 생성·폴더 정리 등으로 나누는 라우팅에 붙여 봤습니다.

모델이 판단한 98개 요청에서 작업 종류와 부가 조건을 모두 맞힌 수는 기존 JSON 방식 77개, 같은 선택지를 받은 GPT-5-nano 63개, Jev 81개였습니다. 판단시간 중앙값도 기존 8.967초에서 Jev 0.658초로 줄었습니다.

같은 100문항으로 API 비용도 봤습니다. Jev 약 \$0.0408, 같은 선택지를 준 GPT 방식 약 \$0.1027이었습니다.

판단

정확도, 속도, 비용 모두 가능성이 보였습니다. 그렇다면 기존 검색이 풀지 못한 답변 근거 선택에도 써 볼 만하다고 생각했습니다.

다른 방법이 아니라 Jev를 고른 이유는 두 가지입니다. GPT에게 근거를 고르게 하면 같은 선택지를 줘도 비용이 약 2.5배였고 판단 시간도 길었습니다. 질문마다 수백 개 후보를 검사하는 단계에는 너무 무거웠습니다. 검색 점수를 조정해 순위를 다시 매기는 쪽은, 하이브리드 가중치와 RRF를 여러 값으로 실험해도 점수가 비슷한 수준에 머물렀습니다. 임베딩이 한국어 표현의 차이를 충분히 구분하지 못하는 경우가 있어, 분야마다 다른 질문에 하나의 가중치를 맞추는 것으로는 개선 폭이 작다고 봤습니다. 그래서 순위를 더 다듬기보다, 모아 온 후보에서 필요한 근거를 직접 판단하게 했습니다.

실험과 개선 과정 (계속)

2 전체 근거 검사로 평가 질문 90건의 근거 총족

문제 상황

질문 원문으로 검색하고 의미 점수의 비중을 높이자, 질문 110개에서 정답 자료가 첫 번째에 나오는 경우가 50개에서 57개로 늘었습니다. 하지만 일부 편향된 실험이었고, 새로운 질문에서도 필요한 근거를 안정적으로 고르는 문제는 그대로였습니다.

시도와 결과

라우팅에서 효과를 본 Jev가 검색이 놓친 근거도 찾을 수 있는지 확인했습니다. 테스트용 위키의 근거 2,020개를 검색으로 거르지 않고 모두 검사한 뒤, 기존 검색과 똑같이 최대 8개를 반환하게 했습니다.

의역을 인정한 의미 평가에서 답이 있는 90개 질문의 근거 총족률은 기존 24/90건(26.7%)에서 Jev 90/90건(100%)이 됐습니다. 답이 없는 질문 10개에는 근거를 하나도 반환하지 않았습니다. 처리시간 중앙값은 기존 1.511초, Jev 5.338초였습니다. Jev는 80개씩 나눈 26개 묶음을 최대 4개씩 병렬 처리했습니다.

전수 검사는 100질문에 2,600회를 호출했고, API가 보고한 사용량은 입력 약 1억 2,448만 토큰, 출력 약 647만 토큰이었습니다. 실제 청구액은 확인하지 않았습니다.

차이가 너무 커서 기존 검색의 탈락 단계도 추적했습니다. 정답 문장을 가진 페이지는 90문항 모두 초기 후보에 있었습니다. 그런데 76문항은 검사 대상을 앞 8개 페이지로 제한하는 단계에서, 8문항은 페이지 내부 최고 점수의 85% 기준에서, 나머지 2문항은 최종 근거 8개 제한과 관련 페이지 탐색에서 빠졌습니다.

판단

기존 검색은 고르기도 전에 정답을 버리고 있었습니다. 그러니 이 차이를 같은 후보에서의 선택 능력 차이로만 볼 수는 없었습니다. 전체 근거를 보면 필요한 정보를 찾을 수 있지만, 질문마다 모든 근거를 검사하면 문서가 늘수록 호출량도 늘어납니다. 이 테스트 위키의 90문항 결과만으로 적용 범위를 정하지 않고, 검색으로 후보를 먼저 줄인 뒤 Jev가 근거를 고르게 바꾸기로 했습니다.

실험과 개선 과정 (계속)

3 동일 500개 후보 비교에서 근거 총족률 87.50% 달성

문제 상황

전체 근거 실험은 질문마다 26묶음을 호출해야 했습니다. 게다가 특정 기술 문서에 질문이 몰려 있었고, 질문에 문서 제목까지 들어 있었습니다. 기존 검색은 일부 페이지만 보고 Jev는 전체 근거를 봤으니, 정확도 차이가 판단력 때문인지 볼 수 있는 범위 때문인지 가리기 어려웠습니다. 후보를 줄이면서 비교 조건도 맞춰야 했습니다.

시도와 결과

논문 9편으로 질문 100개를 새로 만들고, 기존 평가 질문은 다시 쓰지 않았습니다. 한 논문에서 답을 찾는 질문 63개, 두 논문을 이어야 하는 질문 17개, 답이 없는 질문 20개로 구성하고 질문·정답·필수 사실을 실행 전에 고정했습니다.

중복 근거를 합친 뒤 BGE-M3와 BM25로 최대 500개 후보를 한 번만 추려, 두 방식에 같은 본문과 정보를 줬습니다. 기존 선택기도 후보에 속한 모든 페이지를 볼 수 있게 했고, 양쪽 모두 최대 8개 근거를 본문을 자르지 않고 반환하도록 맞췄습니다. 정답은 검색과 Jev 입력에서 뺐습니다. GPT와 Gemini는 방식 이름과 상대 결과를 보지 않고 각각 채점했고, 실행 순서도 번갈아 배정했습니다.

이 조건에서 GPT 기준 근거 총족률은 기존 53/80건(66.25%)에서 Jev 70/80건(87.50%)으로 올랐고, Gemini 채점도 52/80건에서 74/80건으로 개선됐습니다. 답 없는 질문에 근거를 반환한 경우는 20건에서 1건이 됐습니다. 후보 추리기를 포함한 처리시간 중앙값은 기존 0.431초, Jev 9.090초였습니다. 이때 Jev는 묶음을 순차 처리했습니다.

판단

조건을 맞춰도 Jev가 근거를 더 잘 골랐습니다. 그래서 검색은 후보 수집, Jev는 최종 근거 판단을 맡는 구조를 유지했습니다. 다만 공개 논문과 직접 만든 질문의 결과라 일반적인 정확도로 단정하지는 않았습니다. 순차 호출의 대기 시간이 길어, 다음에는 후보 수와 묶음 처리 방식을 조정하기로 했습니다.

실험과 개선 과정 (계속)

4 300개 후보·4병렬 처리로 대기 시간 단축

문제 상황

근거 선택은 좋아졌지만, 후보 최대 500개를 순차 처리하니 준비와 선택 시간의 중앙값이 9.090초로 기존 0.431초보다 길었습니다. 정확도는 지키면서 대기 시간을 줄여야 했습니다.

시도와 결과

후보를 상위 300개로 줄이고 최대 4개 묶음을 병렬 처리했습니다. 시간은 2.251초로 줄었고, 필요한 근거를 모두 고른 질문은 70개에서 73개로 늘었습니다.

판단

그래도 2.251초는 기존 0.431초보다 느렸습니다. 후보를 더 줄이고 병렬 묶음을 늘리는 안도 고민했지만, 필요한 근거가 250위 밖에 있는 사례가 있어 접었습니다.

처리 시간은 늘었습니다. 그래도 이 서비스의 핵심은 정확한 근거라고 보고 Jev를 채택했습니다.

5 후보 생성 방식 비교로 운영 설정의 한계 확인

문제 상황

Jev가 아무리 잘 골라도 필요한 근거가 후보에 없으면 소용이 없습니다. 지금 쓰는 후보 생성 방식이 정답 근거를 어디까지 남기는지 확인해야 했습니다.


시도와 결과

저장된 점수를 재사용해 후보 생성 네 방식의 순위를 다시 만들고, 정답이 있는 80문항·사전 인용 97묶음의 보존을 비교했습니다. BGE-M3 단독, 운영 중인 혼합(임베딩 0.75 + 정규화 BM25 0.25), RRF, 교대 합집합입니다.

후보 100개에서 정답 인용을 모두 남긴 문항은 BGE-M3 단독 74/80, 운영 혼합 63/80, RRF 63/80, 교대 합집합 65/80이었습니다. 인용별 최선 순위의 MRR@500은 BGE-M3 단독 0.1811, 운영 혼합 0.1245였고 순위 중앙값은 19위와 40위였습니다. 후보를 300개 이상으로 늘리면 네 방식의 차이는 79/80과 78/80으로 좁아졌습니다.

판단

운영 중인 혼합 가중치가 BGE-M3 단독보다 정답 근거를 뒤로 밀고 있었습니다. 다만 저장 점수를 재사용한 재현이고 이미 여러 번 쓴 평가셋이라 독립 검증으로 보지 않았습니다. 후보 300개인 지금 구성에서는 차이가 작아 운영 설정을 바로 바꾸지 않았고, 후보를 더 줄이려면 이 순위 차이부터 풀어야 한다는 조건으로 남겼습니다.



근거 충족 건수 53/80 → 73/80, 총 처리시간 2.251초

근거 충족률(Golden set을 통한 LLM 평가)

66.25% → 91.25%

기존 선택기 53/80 → Jev 개선안 73/80

Jev 근거 선택 시간

중앙값 9.090초 → 2.251초

500후보 순차 → 300후보 4병렬

답 없는 질문 20건에 대한 근거 반환

20건 → 0건

기존 선택기 → Jev 개선안

자체 제작 Golden Set 기준, 답이 있는 80개 질문에서 필요한 사실을 모두 뒷받침한 비율이 66.25%에서 91.25%로 올랐습니다. 별도 20개 질문에서는 답이 없는 문서에 근거를 잘못 붙인 경우가 20건에서 0건이 됐습니다. 개선 후에도 기존 선택기보다는 느립니다. 그래도 이 서비스에는 정확도가 더 중요하다고 보고 Jev를 채택했습니다. 같은 뜻의 표현을 묶는 판단에도 써 봤습니다. 76문항의 정답 수는 기존 71개·Jev 72개로 비슷했고, 판단시간 중앙값은 8.162초에서 0.254초로 줄일 가능성을 확인했습니다.

결과의 범위 · 트레이드오프

시간 단축은 Jev 설정을 바꾸기 전후의 비교입니다. 검색은 후보 수집, Jev는 최종 근거 판단을 맡도록 단계를 나눠 선택 방식만 바꿔 끼울 수 있게 했습니다. Jev는 2026년 9월에 공개된 외부 판단 모델이라 장기 운영 근거는 아직 없고, 개선 후에도 기존 선택기보다 느립니다. 답변은 스트리밍으로 전달하지만 근거 선택은 답변 전에 끝나야 해서 2.251초는 사용자 대기로 남습니다. 이 구간을 줄이는 일은 과제로 남겼습니다. 후보 생성 비교는 저장된 점수를 재사용한 순위 재현이며, 최종 답변 정확도가 아니라 후보 보존율입니다.

Jev 공식 소개 · TypeSafe AI ↗

사용자 정의 Agent Skill과 안전한 실행 설계

회의록 생성처럼 반복하는 문서 작업을 사용자가 직접 정의하고 다시 쓸 수 있도록 Agent Skill을 설계하고, AI 코딩 도구로 구현했습니다. 지침 작성과 검사부터 사용자의 검토·게시, 실제 변경 승인까지 한 흐름으로 이었습니다.

2026.08 - 2026.09

LangGraph

Agent Skill

Prompt Injection 대응

LLM Evaluation

Human-in-the-loop

컨텍스트 엔지니어링

대화 요약 메모리

LangSmith

LLM Observability

배경

회의록 정리처럼 사용자마다 반복하는 작업이 달라, 개발자가 전부 미리 만들 수는 없었습니다. 또 AI가 만든 편집안이 요청 일부를 빠뜨리거나 문장을 어색하게 바꾼 채 사용자에게 넘어갔고, 코드의 형식·범위 검사만으로는 걸러내지 못했습니다.

기존 Agent

94 / 114

코드 수정 · 평가자 제외

98 / 114

평가자 포함 최종 구현

104 / 114

판단과 구현 과정

1 사용자 정의 작업 지침의 작성·게시 기능 구현

문제 상황

회의록 정리처럼 사용자마다 반복하는 작업이 달라, 개발자가 모두 미리 만들어 둘 수는 없었습니다.

판단

기능을 하나씩 늘리는 대신, 사용자가 자연어로 작업 지침을 정의하고 다시 쓰게 하기로 했습니다. AI가 만든 지침은 사용자가 검토하기 전까지 제안으로만 다룹니다.

구현

자연어 요청을 다시 쓸 수 있는 Markdown Skill로 정리했습니다. 사용자가 초안을 검토·수정해 게시할 때 Skill과 버전을 저장합니다. 게시한 Skill은 덮어쓰지 않고 불변 버전으로 덧붙이고, 실행할 버전을 가리키는 포인터를 따로 뒀습니다. 어떤 실행이 어느 버전을 썼는지 추적할 수 있고, 새 버전에 문제가 생겨도 이전 정의가 남습니다.

확인한 결과

작성 단계에서는 제안만 돌려주고 아무것도 저장하지 않는지, 게시하면 새 버전이 생기고 실행 버전이 그쪽을 가리키는지, 다른 워크스페이스나 /명령으로도 게시한 Skill을 불러오는지 Skill 모듈 단위 테스트로 확인했습니다. 기능을 마쳤을 때 Skill 모듈 74개와 파이프라인 전체 546개 테스트를 통과했습니다.

판단과 구현 과정 (계속)

2 작업 지침의 권한·승인 우회 방지 검증

문제 상황

사용자가 만든 지침과 참고 문서에는 개인정보나 권한·승인을 건너뛰라는 지시가 섞일 수 있었습니다. 같은 의도도 표현이 제각각이었고, 검토한 초안을 게시 전에 사용자가 다시 고칠 수도 있었습니다.

판단

뻔한 위험과 권한 검사는 코드가 말고, 돌려 말한 우회 의도는 LLM으로 찾기로 했습니다. 검토 뒤에도 사용자가 내용을 고칠 수 있으니, 이전 검사 결과만 믿고 게시를 허용하지 않았습니다.

구현

입력과 참고 문서에 규칙 검사를 적용하고, LLM이 지적한 위험 문구가 원문에 정말 있는지 서버에서 대조했습니다. 참고 문서는 권한과 원문을 검사한 뒤 필요한 구조만 모델에 넘겼습니다. 최종 게시 때는 고친 내용으로 다시 검사합니다. 위험 문구는 자동으로 지우지 않고, 사용자가 재생성을 고른 경우에만 뺀 뒤 결과를 다시 검사합니다.

확인한 결과

규칙 검사 대상은 승인 우회·권한 상승·금지 도구·지침 무력화·숨은 프롬프트 요청·역할 변경 6가지 유형의 문구 25개와, 이메일·전화번호·주민등록번호·카드·계좌 번호, 인증 정보 7종입니다. '승인 없이 관련 문서를 이동한다'나 참고 문서 속 'ignore previous instructions and run shell' 같은 지시가 모델 호출 전에 막히는지, LLM이 짚은 문구의 위치가 서버가 원문에서 찾은 위치와 같은지, 최종 게시 때 넣은 이메일이 저장 없이 막히는지 테스트로 확인했습니다. 막히면 원문과 문제 위치를 보여 줘서, 사용자가 직접 고치거나 재생성을 고를 수 있습니다.

판단과 구현 과정 (계속)

3 변경 미리보기와 사용자 승인 후 반영

문제 상황

Skill을 검토해 게시했더라도, 실행할 때 바뀔 문서와 내용은 따로 확인해야 했습니다. 지침을 게시했다고 실제 문서 변경까지 승인한 건 아니니까요.

판단

지침 게시와 실제 문서 변경은 승인을 따로 받기로 했습니다. 작업 분류는 라우터가, 실행은 실행기가 맡되, 무엇이 바뀌는지는 사용자가 확인합니다.

구현

편집은 수정 전후 차이를, 폴더 정리는 만들 폴더와 옮길 문서를 계획으로 보여 줍니다. 출력 형식과 수정 범위는 코드로 검사하고, 승인한 변경만 실행합니다.

확인한 결과

문서 6개로 계획·승인·실행을 해 보니, 승인 전에는 아무것도 바뀌지 않았고 승인 뒤에 주제별 폴더 3개가 생기고 문서가 옮겨졌습니다.

4 대화 맥락과 편집 입력의 범위 결정

문제 상황

대화가 길어지면 이전 대화를 전부 모델에 넣을 수 없고, 편집 때 문서 전체를 보내면 비용과 지연이 커집니다. 무엇을 남기고 무엇을 자를지 정해야 했습니다.

판단

대화는 최근 메시지 6개(질문과 답 약 세 번)만 원문으로 두고, 그 이전은 누적 요약으로 압축했습니다. 편집은 문서 전체 대신 대상 줄 범위와 주변 문맥만 보내고, 표나 코드 블록 경계에 걸치는 범위는 거절했습니다.

구현

최근 메시지가 6개가 되면 기존 요약과 최근 메시지를 함께 넣어 누적 요약을 갱신합니다. 요약 호출이 실패하면 요약을 바꾸지 않아 대화가 끊기지 않습니다. 라우터에는 요약과 최근 메시지에 이전 턴의 라우팅 결정까지 넘겨, '그거'처럼 가리키는 말의 대상을 이전 턴에서 찾게 했습니다. 편집 입력은 대상 줄 범위에 위아래 문맥 줄을 붙여 자르고, 구조 경계를 걸치는 범위는 예외로 막았습니다.

확인한 결과

1,000줄 문서에서 모델에 보낸 입력은 원문 31,999자 중 1,786자(5.58%), 5,000줄에서는 1.12%였습니다. 입력을 만드는 시간의 p95는 각각 7.7ms, 34.4ms였습니다. 표·코드 블록·수식에 일부만 걸치는 범위가 모두 거절되는지도 테스트했고, 실제 HTTP 요청 3회 중 코드 블록 일부를 고른 요청은 422로 막혔습니다.

판단과 구현 과정 (계속)

5 LLM 실행 추적과 민감정보 경계 설정

문제 상황

평가 루프가 평범한 Python 흐름이라 의미 추출·평가·보정·재시도를 단계별로 볼 수 없었습니다. 그렇다고 추적을 켜면 도구 조회 원문과 개인정보가 외부 추적 도구로 나갈 수 있었습니다.

판단


봐야 하는 구간과 내보내면 안 되는 내용을 나눴습니다. 응답 품질을 다루는 그래프는 노드 단위로 추적하고, 사용자 문서를 직접 만지는 Agent 그래프는 추적을 끄고 원문을 상태에 남기지 않기로 했습니다.

구현

평가 루프를 LangGraph 그래프로 다시 짜서 응답 생성·평가·재시도를 각각의 노드로 드러냈습니다. 추적 설정이 켜져 있어도 키가 없으면 실행은 그대로 하고 추적만 건너뛰어, 경고와 불필요한 네트워크 재시도를 없앴습니다. Agent 그래프는 추적을 끄고 도구 조회 원문을 상태 저장에서 뺐고, 보관 기간이 끝나면 저장 상태를 실행 기록보다 먼저 지웁니다. 직접 남기는 프롬프트 로그는 기록 전에 숫자 개인정보를 마스킹합니다.

확인한 결과

요청을 실제로 실행해 그래프 노드와 모델 호출 구간이 추적에 잡히는지 확인했습니다. 시간을 재는 실험은 추적과 프롬프트 로그를 모두 끄고 돌려, 계측 부담이 측정값에 섞이지 않게 했습니다.



사용자 정의 작업과 승인 흐름 구현 · 편집 품질 82.5% → 91.2% (114건 평가)

기존 Agent

94 / 114

82.5%

코드 수정 · 평가자 제외

98 / 114

86.0%

평가자 포함 최종 구현

104 / 114

91.2%

사용자가 반복 작업을 직접 정의해 Skill로 게시하고 다시 쓸 수 있게 했습니다. 게시할 때는 최종 내용을 다시 검사하고, 실제 문서 변경은 미리보기와 사용자 승인을 거칩니다. 문서 6개로 폴더 정리를 계획·승인·실행해 보니, 승인 뒤에만 변경이 일어났습니다. 편집 품질은 19종 요청에서 나온 같은 초안 114개로 따로 비교했습니다. 기존 구현은 94개가 통과했습니다. 요청을 다시 해석하며 생기는 오류를 줄이려고 편집 목적을 편집 단계까지 넘기고 역할별 규칙을 나눴습니다. 구간 편집에서 고정 문구가 중복되던 문제는 조립된 이전 결과와 실패 사유를 재시도에 넘겨 고쳤고, 여기까지 98개가 통과했습니다. 이어 요청 충족과 의미 보존을 별도 LLM 평가로 검사하고, 실패 사유를 반영해 한 번만 다시 쓰게 하자 104개가 통과했습니다. 그런데 평가 단계가 생성용 JSON 형식까지 따지며 멀쩡한 안을 거부했습니다. 그래서 생성·평가 프롬프트를 분리했고, 제목 추가와 서식 변경을 함께 요청할 때 과하게 막던 보존 검사도 고쳤습니다. 다시 실패하면 수정안을 반환하지 않습니다. AI는 작업 지침과 수정안을 쓰고, 코드는 권한과 실행 범위를 검사하고, 사용자는 게시와 최종 반영을 결정하도록 책임을 나눴습니다.

결과의 범위 · 트레이드오프

편집 품질 평가의 환산 평균 시간은 11.11초에서 18.92초로 늘었습니다. 지연은 감수하되 재작성 횟수는 제한했습니다.

구현 회고 - 사용자가 직접 만드는 Agent Skill [↗](#) 후속 회고 - 신뢰도를 위한 LLM 평가의 양면성 [↗](#)

CASE 03

Fruition / AI Agent · 보상 복구 · 감사 이력

AI 작업 취소와 이미 저장한 변경의 복구

AI 작업은 모델 호출 사이사이에 문서·폴더·Wiki·Skill을 여러 번 저장합니다. 실행만 멈추면 취소한 작업의 일부가 남아서, 이미 커밋한 변경까지 역순으로 되돌리는 경로를 만들었습니다. 다른 작업이 남긴 정상 기여는 지우지 않도록, append-only 이력에서 대상 기여만 빼고 복원했습니다.

2026.08 — 2026.09

보상 복구

먹등기

append-only 이력

PostgreSQL 실행 잠금

감사 이력

배경

여러 저장소에 걸친 AI 작업은 긴 트랜잭션 하나로 묶을 수 없었습니다. 그 상태에서 사용자가 취소하면 무엇을 어디까지 되돌릴지 정해야 했습니다.

복구 대상 저장소

3곳

복구 실행

**모델 호출
없음**

취소 확정 조건

**전체 복구
확인**

판단과 구현 과정

1 실행 중단만으로는 부족하다는 판단

문제 상황

AI 작업은 모델 호출 사이사이에 문서·폴더·Wiki·Skill을 여러 번 저장합니다. 그래서 실행만 멈추면 취소한 작업의 일부가 그대로 남았습니다. core DB, AI DB, 객체 저장소에 걸친 실행을 긴 트랜잭션 하나로 묶을 수도 없었습니다.

판단

이미 커밋한 변경까지 되돌리기로 했습니다. 모델에게 반대 작업을 시키면 원래 값과 승인 범위, 멍등성을 보장할 수 없었습니다. 서비스 전체를 트랜잭션 하나로 잠그면 모델·HTTP·객체 저장소의 긴 실행과 장애를 버틸 수 없었습니다. 둘 다 접었습니다.

구현

AI 쪽은 실행 기록으로 역작업을 정하고, 업무 데이터의 원자적 복구는 backend가 맡도록 나눴습니다. Agent 도구는 변경 전 snapshot과 원래 승인에 묶인 역작업 인자·멍등키를 저장하고, 일반 작업은 각 DB의 trigger로 변경 전후 값을 같은 트랜잭션에 기록했습니다. 객체 저장소는 쓰기 전에 원본과 예정 결과를 남겼습니다.

확인한 결과

실제 worker로 돌리는 테스트에서 복구 중 모델을 만들면 실패하게 해 두고, 모델과 게이트웨이를 한 번도 부르지 않고 취소가 끝나는 걸 확인했습니다. 폴더 2개·문서 6개를 정리하는 작업을 9개 지점 각각에서 취소해도 원래 상태로 돌아왔고, 응답이 유실된 뒤 새 worker가 같은 멍등키로 복구를 이어 가는 것도 확인했습니다.

2 취소 이후의 쓰기를 막고 자식부터 역순으로 복구

문제 상황

취소를 받아도 실행 중인 handler가 계속 쓰면, 복구한 값이 다시 덮였습니다. 부모 작업부터 되돌리면 자식이 남긴 변경이 그대로 남았습니다.

판단

취소 상태를 먼저 저장해 이후 쓰기를 막고, 실행 중인 handler가 끝나면 자식부터 역순으로 되돌렸습니다.

구현

Agent 턴과 복구가 같은 PostgreSQL 실행 잠금을 쓰게 했습니다. worker 연결이 끊기면 잠금도 풀리니, 남은 실행 중 기록이 복구를 막지 않습니다. 본문은 새 revision으로 복구해, 늦게 도착한 이벤트가 원문을 다시 덮지 못하게 했습니다.

확인한 결과

취소 뒤 쓰기는 거부되고, 실행 중인 handler가 끝날 때까지 복구가 기다리며, 자식이 부모보다 먼저 되돌려지는 것을 테스트로 확인했습니다. 프로세스를 강제로 종료해도 복구는 같은 잠금을 기다렸다가 끝났고, 늦게 온 이전 revision 이벤트는 복구한 본문을 덮지 못했습니다. 그사이 다른 사용자가 바꾼 내용이 있으면 덮지 않고 재시도 상태로 남겼다가, 충돌이 풀린 뒤 다시 취소하면 정상 완료되는 것까지 봤습니다.

판단과 구현 과정 (계속)

3 다른 작업의 기여를 지우지 않는 복구

문제 상황

Wiki의 개념 페이지는 여러 문서의 기여를 합친 결과입니다. 특정 작업을 과거 snapshot으로 덮으면, 이후 들어온 다른 문서의 정상 기여까지 사라졌습니다.

판단


완성된 결과에서 해당 부분만 지우는 방법은 어느 문장이 어느 문서에서 왔는지 안정적으로 가릴 수 없었습니다. 과거 snapshot으로 통째로 되돌리는 방법도 접었습니다. 대신 이력은 덧붙이기만 하고, 복구할 때 대상 기여만 빼고 다시 조립했습니다.

구현

작업, 페이지 revision, 문서별 기여를 덧붙이기만 하는 이력으로 남기고, 복구 때는 대상 기여를 뺀 상태로 복원하거나 다시 조립했습니다. 페이지와 이력은 지우지 않고 삭제 표시만 남겨 감사 이력을 보존했습니다.

확인한 결과

복구 직전에 잠금을 잡고 기여 목록(작업·revision·활성 여부)을 다시 읽어, 미리보기 때와 다르면 복구를 거부했습니다. 고른 기여만으로 페이지를 다시 만들고, 한 페이지라도 실패하면 현재 상태를 하나도 바꾸지 않는 것을 테스트로 확인했습니다. 복구도 새 작업과 revision으로 남겨 무엇을 되돌렸는지 기록했습니다.



취소한 작업이 남긴 변경을 되돌리고, 다른 작업의 기여는 유지

복구 대상 저장소

3곳

core DB · AI DB · 객체 저장소

복구 실행

모델 호출 없음

실행 기록의 역작업만 사용

취소 확정 조건

전체 복구 확인

미확인은 재시도 상태로 보존

사용자에게 보이는 내용, 이름, 부모, 순서는 되돌리고 버전·감사·역등 기록은 남겼습니다. 복구는 모델 설정이나 호출 없이 실행 기록만으로 하고, 현재 값과 후속 참조를 확인해 다른 작업의 변경은 덮지 않습니다. 전체 복구가 확인돼야 취소가 확정되고, 충돌이나 불분명한 결과는 재시도 상태로 남깁니다. AI가 문서를 바꾸는 기능이라면 되돌릴 범위와 남길 기록부터 정해야 한다는 걸 구현하며 배웠습니다. 실제 Gemini·Kafka·PostgreSQL·Redis 환경에서 직접 돌려 보니 승인 전에는 아무것도 바뀌지 않았고, 마지막 문서 이동 중에 취소하자 역작업 8개로 폴더 2개와 문서 6개가 원래대로 돌아왔습니다.

결과의 범위 · 트레이드오프

설계와 단위 검증 중심의 사례이고, 운영 트래픽에서의 복구 성공률은 재지 않았습니다. Ingest 때부터 Source별 기여를 보존해야 해서 저장 비용이 늘어납니다. 남은 기여 조합의 snapshot이 없으면 Page를 다시 조립해야 하고, snapshot이 없는 구버전 작업 때문에 배포 전에 실행과 큐를 비워야 했습니다.

PDF → Markdown 변환 - 내부 평가 통과율 45.17% → 89.89% 개선

논문은 주로 PDF로 오기 때문에, Markdown으로 바꿀 때 표의 수치와 수식부터 지켜야 했습니다. AI로 고치는 과정에서 생기는 누락을 추적하고, 원본 배치와 내용 유형에 맞춰 처리 경로를 나눴습니다.

2026.07 — 2026.09

PDF 변환 오픈 소스 : AnyDoc, Docling

LLM API

sLLM (Qwen2.5 7B)

Python

LLM-as-a-Judge

배경

논문 PDF를 지식으로 쓰려면 본문뿐 아니라 표·수식·그림까지 살린 Markdown이 필요했습니다.

기존 Docling

45.17%

개선 파이프라인

89.89%

실험과 개선 과정

1 손상 영역 선택 복원과 탐지 누락 확인

문제 상황

오픈소스로 PDF를 Markdown으로 바꾸자 표의 행·열 관계와 수식이 깨졌습니다. 전체를 다시 돌리지 않고 잘못 바뀐 부분만 고칠 방법이 필요했습니다.

시도와 결과

깨진 부분만 골라 고치면 되겠다고 생각했습니다. Docling으로 구조를 뽑고 손상된 표·수식만 로컬 Qwen sLLM으로 복원했습니다. 행·열 위치가 중요한 표는 비전 모델(qwen2.5vl:7b) 중심으로, 수식은 텍스트 모델(qwen2.5:7b)로 후보를 만든 뒤 필요할 때만 비전 모델로 확인했습니다. 두 모델을 모두 쓸 때보다 복원율이 높았고 sLLM 처리 시간은 약 42% 줄었습니다. OCR과 프롬프트는 두고 crop만 Docling의 엄격한 bbox로 다시 자르자, 실패하던 두 수식이 모두 정확히 복원되기도 했습니다.

실제로 sLLM이 고친 96개 중 85개는 통과했습니다. 그런데 손대지 않은 쪽을 열어 보니 오류·누락이 107개나 남아 있었습니다. OCR 대조를 더한 별도 실험에서는 통과율이 80.00%에서 97.53%로 올랐지만, 멀쩡한 내용 50개까지 고칠 대상으로 골랐고 처리 단계의 시간 합은 약 12분 35초였습니다.

판단

고칠 곳을 고르는 단계부터 오류를 놓치고 있었고, 이를 메우는 검사에도 비용이 들었습니다. 이럴 바엔 원본 페이지 전체를 비전 sLLM이 읽게 하는 게 낫지 않을까 생각했습니다.

2 전체 페이지 sLLM 변환의 표·수식 오류와 비용 확인

문제 상황

고칠 곳만 고르는 방식은 오류를 놓쳤고, OCR 대조를 더하면 멀쩡한 내용까지 고르면서 검사 시간과 비용이 늘었습니다.

시도와 결과

그래서 논문 PDF 25개(415쪽)를 원본을 직접 보는 비전 sLLM(qwen2.5vl:7b)으로 통째로 처리했습니다. 내용 보존 통과율은 91.92%였지만, 표·수식의 값과 구조가 모두 맞은 비율은 58.84%에 그쳤고 모든 페이지를 처리하는 부담도 컸습니다.

판단

모든 내용을 같은 방식으로 모델에 맡긴 게 문제였습니다. 본문은 필요한 곳에만 AI를 쓰고, 표·수식은 각자의 구조를 살릴 수 있는 입력을 줘야겠다고 판단했습니다. 그래서 본문·표·수식의 경로를 나누고, 본문은 빠르게 뽑으면서 필요한 곳만 AI로 고칠 방법을 찾았습니다.

실험과 개선 과정 (계속)

3 본문 추출 비교, AnyDoc 적용과 상용 API 전환

문제 상황

페이지 전체를 sLLM으로 돌려도 표·수식 오류가 남았고, 본문까지 전부 모델에 보내는 부담이 컸습니다. 표·수식은 따로 복원하되 본문은 빠르게 뽑을 방법이 필요했습니다.


시도와 결과

그러다 Threads에서 PDF 변환 도구 AnyDoc을 알게 됐고, GitHub의 Docling 대비 평가 결과를 보고 기존 실험의 PDF 4개(30쪽)로 비교했습니다.

기존 Docling 처리 기록은 134.19초, AnyDoc의 텍스트 추출은 1.68초로 약 80배 짧았습니다. 다만 Docling은 OCR과 표 분석까지 포함한 시간이었습니다. AnyDoc에서는 한 문서의 글자가 깨졌는데, PDF 안에서 글자 코드를 실제 문자로 잇는 정보가 빠져 있었기 때문이었습니다.

판단

처리 범위가 달라서 전체 변환이 80배 빨라졌다고 볼 수는 없습니다. 그래도 본문을 빠르게 뽑는 데는 쓸 만하다고 판단했습니다. 표·수식 복원은 그대로 두고 본문 추출만 AnyDoc으로 바꿨고, 글자가 깨지거나 읽는 순서가 섞인 페이지는 AI로 보완했습니다. 그림은 원본을 살렸습니다. 또 초기 사용자가 없는 단계라 GPU 서버로 sLLM을 운영하는 비용이 더 크다고 보고, 이때부터 복원 모델을 상용 LLM API로 바꿨습니다.



30페이지 원문 대조에서 실사용 기준 통과율 45.17% → 89.89%

기존 Docling

45.17%

총 30페이지

개선 파이프라인

89.89%

총 30페이지

같은 논문의 본문·표·수식 등을 445개 평가 단위로 나눠 원문과 대조했고, 기존 Docling과 개선한 파이프라인은 이름을 숨기고 평가했습니다. 실사용 기준 통과율은 201개(45.17%)에서 400개(89.89%)로, 값·기호까지 똑같아야 하는 엄격 기준은 193개(43.37%)에서 393개(88.31%)로 올랐습니다.

결과의 범위 · 트레이드오프

PDF 4개(30쪽)에 대한 내부 LLM 평가입니다. 본문, 제목, 그림은 경미한 차이를 허용했고, 표와 수식은 값, 기호, 구조가 일치해야 통과시켰습니다.

[PDF → Markdown에 SLLM 사용해보기 ↗](#) [PDF 변환 오픈소스 AnyDoc을 사용해보자 ↗](#)

CASE 05

Fruition / Kafka 비동기 병렬 처리 · AI 파이프라인

문서 병렬 분석 - 처리시간 282.11초 → 73.89초 단축

Wiki 생성이 문서를 하나씩 처리하는 구조라, 큰 문서가 들어오면 사용자가 오래 기다려야 했습니다. Worker를 늘리면 얼마나 빨라지고 자원은 얼마나 더 드는지 확인했고, 문서 분석과 벡터 생성의 확장 기준을 따로 세웠습니다.

2026.09

AI 파이프라인

Kafka

PostgreSQL

동시성·메모리

배경

문서를 하나씩 처리하니 뒤 문서가 앞 문서의 외부 AI 응답을 계속 기다렸습니다. Worker를 1개에서 4개로 늘리자 분석 시간이 282.11초에서 73.89초로 줄었습니다. 동시성을 더 높이면 더 빨라질 거라 생각해 Worker 안의 동시 AI 요청을 2개에서 4개로 늘리자 오히려 95.92초로 느려졌고, 같은 GPU에서 벡터 생성을 2개 돌리자 각각 약 9.5초에서 19~21초로 늘었습니다. 외부 응답을 기다리는 분석과 장치를 나눠 쓰는 벡터 생성은 병렬화 효과가 달라, 단계별로 확장 기준을 나눴습니다.

Worker 1개


282.11초

Worker 4개

73.89초

프로세스 메모리 합

약 4배



문서 4개 분석 시간 73.8% 단축 · 문서 100개 큐 재현 300건 누락·실패 0건

Worker 1개

282.11초

4문서(8번의 호출)

Worker 4개

73.89초

최대 API 동시 요청 8개

프로세스 메모리 합

약 4배

351.7 → 1,401.0MiB

Worker 4개, 각 2개 동시 요청 조건에서 문서 4개의 총 처리 시간을 약 73.8% 줄였습니다. 대신 프로세스 메모리 합이 351.7MiB에서 1,401.0MiB로 약 4배 늘었습니다. 미리 정해 둔 사실 16개 중 완전히 보존된 수도 Worker 1·2·4개에서 10·14·11개로 달라, 조건별 1회의 작은 표본이지만 품질이 같다고 보지는 않았습니다. 동시 요청을 더 늘리는 안과 같은 GPU에서 벡터 생성을 병렬화하는 안은 오히려 느려져 접었습니다. 동시성을 높이면 항상 빨라질 거라는 처음 생각이 틀렸고, 외부 응답 대기과 장치 경합을 다른 문제로 나눠 보게 되었습니다. 저장된 AI 응답으로 문서 100개의 큐 처리를 3가지 조건에서 재현했고, 총 300건 모두 누락·실패 없이 처리했습니다. 메모리를 약 4배 더 쓰지만 MSA로 EKS에서 AI 기능을 제공해 분산할 수 있다고 보고, 문서 병렬 처리에는 최대 Worker 4개를 쓰기로 했습니다.

결과의 범위 · 트레이드오프

같은 문서로 조건별 1회 분석한 결과입니다. 저장, 후처리까지 포함한 E2E 속도는 아닙니다. Worker 5개 이상은 측정하지 않아, 4개가 최적이라고 주장하지 않습니다.

코딩 에이전트 루프 - MSA 이식 PR 16개를 5일 만에 병합

AI 기능을 MSA 구조로 옮기는 작업은 코딩 에이전트에게 맡기고, 저는 작업 계획과 검토 기준을 정하고 병합 여부를 판단했습니다. 브랜치별 작업 공간마다 에이전트를 나눠 병렬로 돌리고, 조정 에이전트가 순서와 우선순위를 관리하는 루프를 만들었습니다.

2026.08

코딩 에이전트

Claude Code

MSA

코드 리뷰

배경

MSA 전환을 일주일 안에 마쳐야 일정대로 배포하고 새 구조에 대한 피드백도 받을 수 있었습니다. 그런데 기능이 이미 다 만들어져 있어 옮기며 고칠 곳이 너무 많았고, 사람이 직접 하기엔 시간이 모자랐습니다. 작업도 여러 갈래였습니다. 그래서 제가 쉬거나 자는 동안에도 작업이 이어지도록 코딩 에이전트 루프를 만들기로 했습니다. 다만 한 세션에서 오래 작업하면 맥락이 요약되면서 앞서 정한 계획을 놓쳤습니다.

병합 PR

16개

병합 전 필수 수정

13건

브랜치당 에이전트

2개

루프 설계와 판단 과정

1 역할을 나눈 에이전트 루프 구성

문제 상황

한 세션에 모든 작업을 맡기니 맥락이 요약되면서 계획과 기준이 흐려졌습니다.

시도와 결과

작업 계획과 기준을 문서로 고정하고, 구현·검토·통합 리뷰로 역할을 나눴습니다. 브랜치마다 작업 공간을 따로 두고 에이전트 2개를 병렬로 돌렸고, 작업 간 의존성과 우선순위는 조정 에이전트가 판단하게 했습니다.

판단

세션이 바뀌어도 같은 문서를 기준으로 이어갈 수 있어, 긴 작업을 여러 에이전트에 나눠도 방향이 흩어지지 않았습니다.

2 PR 진행 기간: 8/9 → 8/13

문제 상황

작업들이 서로 얹혀 있어, 한꺼번에 열면 충돌과 재작업이 생길 수 있었습니다.

시도와 결과

8/9에 #156-#159를 만들어 8/10에 병합하고, 8/11에 #167-#169-#170 등을 병렬로 진행한 뒤, 8/13 #175에서 통합 결함을 고쳤습니다. 5일 동안 PR 16개를 병합했습니다.

판단

선행 작업이 병합된 뒤에 다음 묶음을 열었고, 병렬로 돌리면서도 충돌을 줄일 수 있었습니다.

루프 설계와 판단 과정 (계속)

3 병합 전 리뷰와 병합 판단

문제 상황

에이전트가 만든 변경을 그대로 병합하면 결함까지 함께 들어갈 수 있었습니다.



시도와 결과

리뷰에서 나온 필수 수정 13건을 반영하고 회귀를 확인한 뒤에만 병합했습니다. 문서를 복구한 뒤 이전 본문이 반환되던 결함도 병합 전에 고쳤습니다.

판단

코드를 직접 쓰지 않는 대신, 통과 기준을 정하고 그 기준으로 병합을 판단하는 것을 제 역할로 삼았습니다.

개선한 처리 흐름



계획과 기준은 제가 정하고, 구현과 검토는 역할을 나눈 에이전트가 브랜치별로 병렬 수행한 구조입니다.

5일 동안 PR 16개 병합 · 병합 전 필수 수정 13건 반영

8월 9일부터 13일까지 5일 동안 PR 16개를 병합했습니다. 병합 전 리뷰에서 나온 필수 수정 13건을 반영하고 회귀를 확인했습니다. 그중에는 문서를 복구한 뒤 이전 본문이 반환되던 결함도 있었습니다. 구현은 코딩 에이전트가 맡았고, 저는 루프 구성, 작업 계획과 기준 문서 작성, 결과 검토와 병합 판단을 맡았습니다.

결과의 범위 · 트레이드오프

코드를 직접 쓰지 않고 기준 문서와 리뷰 결과로 병합을 판단했습니다. 그래서 리뷰 기준에 없는 결함은 놓칠 수 있고, 기준 문서를 계속 보완하는 것이 과제로 남았습니다.

병합 PR

16개

2026.08.09 – 08.13

병합 전 필수 수정

13건

리뷰 지적 반영

브랜치당 에이전트

2개

구현 · 검토

Pilltip

의약품 정보를 쉬운 말로 안내하고, 사용자·가족의 복약 정보와 일정 관리를 돕는 개인 맞춤 AI 복약 서비스입니다.

시작 계기

부산대학교 졸업과제로 시작했습니다. 약품 정보가 여러 곳에 흩어져 있어, 지금 건강 상태에서 이 약을 먹어도 되는지 바로 확인하기 어려운 문제를 풀고 싶었습니다.

GitHub 저장소 [↗](#)

팀 구성과 내 역할

MY ROLE

백엔드·AI

의약품·건강기능식품 DB, 검색·자동완성, 복약 알림, 복용 위험·주의 정보 표출, 데이터 정제, AI 챗봇

01 백엔드·AI 기능 개발

02 의약품·건강기능식품 데이터 모델링, 검색·자동완성과
복용 위험 정보 표출

03 복약 알림과 기록

04 친구, 가족 기능

05 데이터 정제 파이프라인 구축 - 예상 \$200 대비 실제
\$11.18로 변환

06 RAG 기반 AI 챗봇

07 전시 피드백을 반영한 건강기능식품 지원 확대

Android 1명

Kotlin 기반 Android 앱 전반

백엔드·보안 1명

사용자 DB, 로그인, 문진표, AES-GCM 암호화


디자인

디자이너

담당 기능과 서비스 화면

Solution

편리한 사용성
약품 검색 기능



DUR 기반 위험 태그 제공

사용자가 약물을 검색하면, 해당 약물의 성분과 사용자의 건강 정보를 활용하여 DUR(Drug Utilization Review) 평가를 통해 위험도를 평가하고 위험도 표시하여, 일반 사용자도 복용 위험 여부를 직관적으로 파악할 수 있도록.

진료받은 병원과 복용처까지 표시하여

진료받은 병원과 복용처까지 표시하여

DUR 감지 약물


DUR 비감지 약물

의약품 검색·DUR 표출

의약품 DB, 검색·자동완성, 복약 위험정보 표출을 담당했습니다. 데이터 정제 파이프라인으로 약물 설명을 쉬운 말로 변환했습니다. 사진은 검색·주의 태그 화면입니다.

Solution

놓치지 않을 거예요
스마트 복약 알림




복약 알림·로그

FCM을 활용한 알림과 복약 기록 기능을 담당했습니다.

Solution

내가 직접 챙기는
우리 가족 건강 관리




가족 프로필 전환

관리할 가족을 바꾸어 해당 프로필의 복약 정보를 확인하는 기능을 담당했습니다. 딥링크 기반 친구 초대도 구현했으며, 이 화면은 가족 전환 기능을 보여줍니다.

Solution

나만의 약사님
필립 AI 챗봇



AI 챗봇

질문에 따라 RAG 검색과 DUR 확인을 연결하는 오케스트레이션을 담당했습니다. 발표 자료의 예시 대화이며 의약 판단 정확도의 평가 결과는 아닙니다.

CASE 07

Pilltip / 데이터 파이프라인 · GPT Batch API · PySpark

의약품 정제 파이프라인 - 예상 \$200 대비 실제 \$11.18로 변환

어려운 의약품 정보를 쉬운 말로 바꾸려고 데이터 정제 파이프라인을 만들었습니다. 원문을 문장 블록으로 나눠 같은 문장은 한 번만 변환하고, 결과를 각 약품에 다시 붙여 실제 API 지출 \$11.18로 처리했습니다. 2026년에는 같은 정제 과정을 PySpark로 재현해 단계별 감소 효과를 측정했습니다.

2025.07 · 재현 2026.10

데이터 파이프라인

GPT Batch API

PySpark

MinHashLSH

배경

약 4만 4천 건(약 1GB)의 의약품 원문을 그대로 쉬운 설명으로 바꾸면 API 비용이 약 \$200으로 예상됐습니다. 약품 수를 줄이지 않고, 예산 안에서 모든 약품의 설명을 만들 방법이 필요했습니다.

원문 처리 예상 비용

약 \$200

실제 API 지출

\$11.18

완전 일치 중복 제거

-94.1%

문제 분석과 구현 과정

1 완전 일치 문장 중복 제거

문제 상황

약 4만 4천 건, 1GB 규모의 원문을 모두 변환하면 API 비용이 약 \$200으로 예상됐습니다. 예산 안에서 전체 약품의 설명을 만들 방법이 필요했습니다.

시도와 결과

약품 원문 100개를 직접 살펴보니 약 70%가 중복되는 내용이었고, 이 표본 분석과 작업 계획으로 전체 처리 기간 7일을 확보했습니다. 원문을 문장 블록으로 나눠 완전히 같은 문장은 하나로 합치고, 각 약품과 문장 블록의 연결은 남겼습니다.

판단

약품 수를 줄이는 대신 같은 문장을 한 번만 변환해 재사용하기로 했습니다.

2 GPT Batch API 일괄 변환과 약품별 재연결

문제 상황

중복은 건너뛴지만 변환 비용을 더 줄여야 했고, 모델 비용 자체를 낮출 방법도 찾아야 했습니다.

시도와 결과

사용 중에 바로 응답해야 하는 작업이 아니라서 일괄 처리의 대기 시간을 받아들였습니다. 고유 문장을 GPT Batch API로 변환한 뒤, 남겨 둔 약품 ID와 문장 블록 ID의 연결로 각 약품에 결과를 다시 붙였습니다. 전체 원문 변환에 예상했던 약 \$200 대비 실제 API 지출 \$11.18로 변환을 마쳤습니다.

판단

중복 제거와 Batch 변환을 함께 써서, 약품 범위를 줄이지 않고 기능을 만들었습니다.

문제 분석과 구현 과정 (계속)

3 2026 PySpark 재현 - 어미 통일과 유사 문장 통합의 효과 측정

문제 상황

2025년 정제 코드 일부와 원본 파일이 남아 있지 않아, 완전 일치 이후 단계의 효과를 숫자로 설명할 수 없었습니다.


시도와 결과

식약처 공개 API로 42,714개 품목을 다시 수집해 XML 구조대로 블록 3,299,602개로 나누고, PySpark로 정규화와 완전 일치 중복 제거를 재현했습니다. 이어 어미 통일 사전과 MinHashLSH(글자 3-gram, Jaccard 거리)를 적용하고, 임계값 0.1·0.2·0.3의 감소율과 합쳐진 표본을 비교했습니다.

판단

0.3이면 18.78%나 줄었지만 다른 질환(Lapp·Total 유당분해효소 결핍증)의 문장이 합쳐졌고, 0.2에서도 주의 문장 일부가 사라졌습니다. 의료 정보는 잘못 합치는 비용이 커서, 숫자와 적용 조건이 같을 때만 합치는 안전장치와 함께 0.1(추가 6.69% 감소)을 골랐습니다.

개선한 처리 흐름



같은 문장은 한 번만 변환하고 약품별 연결을 보존해 결과를 다시 붙였습니다. 2026년에는 같은 과정을 PySpark로 재현해 측정했습니다.

실제 API 지출 \$11.18 · PySpark 재현에서 텍스트 94.1% 감소

전체 원문을 처리할 때 예상한 약 \$200 대비 실제 API 지출 \$11.18로 변환을 마쳤습니다. 설명할 약품의 범위는 줄이지 않고, 고유 문장의 변환 결과를 재사용해 예산 안에서 기능을 만들었습니다. 2025년 정제 코드 일부가 남아 있지 않아, 2026년에 식약처 공개 API로 42,714개 품목(순수 텍스트 960MB)을 다시 수집하고 같은 정제 과정을 PySpark로 재현했습니다. 블록 3,236,626개가 고유 블록 176,648개로 줄어 텍스트가 744MB에서 44.1MB로 94.1% 감소했습니다. 이어 어미 통일 사전으로 0.78%, MinHashLSH 유사 문장 통합으로 6.69%를 더 줄였습니다.

결과의 범위 · 트레이드오프

약 \$200은 사전 추산이고 \$11.18은 실제 지출입니다. 2026년 수치는 다시 수집한 데이터로 측정해 2025년 처리 데이터와 같지 않습니다. 재현 코드는 AI 코딩 도구로 작성했고, 실험 설계와 임계값 판단을 맡았습니다.

원문 처리 예상 비용

약 \$200

추산치

실제 API 지출

\$11.18

2025 변환 작업

완전 일치 중복 제거

-94.1%

2026 PySpark 재현 · 744MB → 44.1MB

복약 챗봇 - 건강 프로필을 외부 AI 입력에서 분리

RAG 기반 AI 오케스트레이션으로 복약 정보를 안내하는 AI 챗봇을 앱에 넣을 수 있게 했습니다. 증상에 맞는 의약품 탐색과 프로필에 따른 판단은 나눴습니다. 모델의 언어 해석 능력은 쓰되, 민감한 프로필을 쓰는 범위는 코드로 직접 관리했습니다.

2025.09

Spring AI

Weaviate

RAG

AI Orchestration

배경

사용자가 말하는 증상과 약품 효능에 쓰인 단어가 달라, 단어 검색으로는 증상에 맞는 약을 찾기 어려웠습니다. 또 개인화에는 임신 여부·복용약·기저질환이 필요했는데, 이 건강 프로필을 외부 LLM에 그대로 보내면 민감정보가 밖으로 나가는 범위를 통제하기 어려웠습니다.

설계와 구현 과정

1 증상과 약품 효능을 연결하는 의미 검색 구현

문제 상황

사용자가 말하는 증상과 약품 효능에 쓰인 단어는 같은 뜻이어도 달랐습니다. 단어가 겹치지 않아도 관련 정보를 이어 줄 방법이 필요했습니다.

판단

처음에는 증상 동의어 사전을 만들면 되겠다고 생각해 코드까지 작성했습니다. 그런데 다뤄야 할 증상이 너무 많았고, 증상을 여러 개 말하면 사전 항목들이 서로 겹칩니다. 결국 그중에서 그 사람에게 맞는 약을 골라야 하는데, 약품 설명이 모호하면 거의 모든 증상에 걸려 버렸습니다. 그래서 자연어 증상과 약품 효능을 잇는 일은 의미 검색에 맡기고, 질문에 필요한 정보를 주도록 처리 경로를 나눴습니다.

구현

약품 효능을 Weaviate에 저장해, 증상과 뜻이 가까운 정보를 찾게 했습니다. 질문에 따라 약품 탐색·복약 위험·섭취량 정보를 처리하는 경로를 나눴습니다.

확인한 결과

2025년 8월 사용자 시나리오 기반 E2E 테스트에서, 자연어로 증상을 말하면 질문에 맞는 처리 경로(약품 탐색·복약 위험·섭취량)로 이어지는 흐름을 확인했습니다. 증상별 정확도를 수치로 평가한 기록은 남기지 못했습니다.

2 건강 프로필의 내부 처리와 외부 AI 입력 분리

문제 상황

개인화에는 임신 여부·복용약·기저질환이 필요했지만, 이 프로필을 외부 LLM에 넘기면 민감정보가 새어 나갈 수 있었습니다.

판단


처음에는 건강 프로필을 외부 AI에 보내되, 민감한 내용만 걸러내면 되겠다고 생각했습니다. 그런데 걸러야 할 표현과 경우가 너무 많아, 코드로 모두 막기는 어렵다고 판단했습니다. 그래서 증상 표현을 이해하는 일과 건강 프로필의 조건을 판단하는 일을 나누고, 프로필을 쓰는 판단은 입력과 규칙을 직접 관리할 수 있는 내부 코드에 두었습니다.

구현

임신 여부·복용약·기저질환 필드는 외부 LLM 입력에서 뺐습니다. 내부 코드의 프로필 판단을 증상 검색 결과와 이어, 개인화 정보를 주도록 구현했습니다.

확인한 결과

임신 여부·복용약·기저질환은 외부 LLM 호출 입력에 넣지 않고, 내부 Tool이 이 정보로 금기·중복·상호작용을 판단해 해당 약을 걸러 내도록 처리 경로를 나눴습니다. 약 상세 화면의 AI 맞춤 안내에도 이 세 가지 정보는 보내지 않았습니다.



증상 의미 검색과 건강 프로필의 내부 판단 분리

자연어 증상으로 약품 정보를 찾으면서도, 임신 여부·복용약·기저질환 필드는 외부 LLM 입력에서 뺐습니다. AI에 넘길 정보와 내부 코드가 판단할 정보를 나눠 본 경험입니다. 민감정보를 다루는 도메인에서는 모델에 맡길 판단과 코드가 책임질 판단의 경계부터 정하고 구현했습니다.

결과의 범위 · 트레이드오프

프로필 조건이 바뀌면 내부 코드도 고쳐야 하는 부담이 있습니다. 그래도 민감한 건강 정보가 외부 모델로 나가는 범위를 줄이는 게 먼저라, 이 판단은 AI에 맡기지 않고 코드에서 처리했습니다. 특정 프로필 항목을 외부 입력에서 뺐 것이며, 모든 경로의 유출 차단을 측정한 결과는 아닙니다.

코드 밖에서도 이어지는 경험

Rhwp · HWPX 저장 오류 수정

Claude Code에 작업 계획과 기여 규칙을 주고 이슈 분석부터 PR까지 자동화해, textFlow 보존 오류 수정(PR #1213) 등 PR 7건이 병합되고 Contributor로 등재됐습니다.

[GitHub 저장소](#) ↗

APPTIVE · 백엔드 멘토링

멘티 경험을 교육 개선으로 연결했습니다. 멘티 12명을 대상으로 6회의 멘토링과 코드 리뷰를 진행했습니다.

백준 945일 연속 문제 해결

하루 한 문제를 목표로 solved.ac 기준 최장 945일 연속 문제를 해결했습니다. 누적 1,659문제, solved.ac Platinum IV.

[풀이 저장소](#) ↗

프로젝트 회고

ARCHITECTURE / 데이터 소유권

MSA 전환과 피드백

기능별 분리에서 데이터 소유권으로 관점을 바꿨습니다. 비동기 처리의 효과와 늘어난 운영 부담을 함께 기록했습니다.

기획 / 사용자 문제 정의

디자인 싱킹 회고

기능부터 고민하던 기획을 돌아보고, 팀원들이 겪은 문서 탐색의 불편함을 모아 함께 해결할 문제를 정의한 과정입니다.

[블로그 글 더보기 ↗](#)

김재형

AI Application Developer · Backend Engineer

kkuldangi2@gmail.com

martinel2.github.io

github.com/Martinel2

LLM 워크스페이스의 AI 기능 전체를 맡아 RAG와 에이전트, 품질 평가 체계를 설계하고, AI 코딩 도구로 구현·검증했습니다.

정확도와 비용, 응답 시간의 트레이드오프를 평가로 확인한 뒤 서비스에 맞는 구현을 선택합니다.