김재형 | AI Engineer / Backend Engineer

AI를 최대한 활용해 사람들을 이롭게 하는 서비스를 개발하고자 합니다.

kkuldangi2@gmail.com GitHub ↗ Blog ↗ LinkedIn ↗

SUMMARY

RAG 근거 선택 개선: 정답률 71.7% → 93.0%, 근거 적합성 70.0% → 95.4%(질문 100개 × 3회)

에이전트 실행 환경 설계: 사용자 정의 Skill과 승인 기반 실행, 편집 성공률 85.6% → 88.9%(30건 × 3회)

데이터 파이프라인 구축: 유형별 PDF 15개 본문 96.1%, 표 셀 99.3% 복원, 약품 변환 비용 예상 $200 대비 $11.18

PROJECTS & EXPERIENCE

Fruition

2026.04 — 현재

LLM Wiki 기반 AI 워크스페이스 | AI SW 마에스트로 17기 | AWS EKS 배포 완료, QA 진행 중
팀 프로젝트 (3명 + 디자이너) / AI 파트 리드

시작 계기: 팀원이 제기한 문서 관리의 불편함을 디자인 싱킹으로 구체화. 저장만 해 둔 문서를 필요할 때 찾지 못하는 문제를 풀고자 했습니다.
팀 구성: 본인(AI 전체), 백엔드 1명(Spring 백엔드 전체), 프론트엔드와 DevOps 1명(프론트엔드, MSA 기반 AWS 배포), 외주 디자이너, 멘토 3명
사용 언어: AI 서비스 Python(FastAPI, Langchain, LangGraph), 문서 서비스 Java(Spring Boot), 프론트엔드 TypeScript(Next.js)

GitHub | AI 분리 저장소 ↗

RAG 과정의 검색 정확도 개선

저장된 문서에서 AI 답변에 필요한 근거를 찾고, 답이 없는 질문에는 근거를 붙이지 않게 하는 기능입니다.

- 답변 근거 선택 개선
  문제: 문서 근거로 답하는 서비스에서 기존 검색이 근거를 놓치거나 답 없는 질문에도 근거를 붙여 답변 신뢰도가 흔들림.
  판단: 도입 당시 GPT 선택은 비용(약 2.5배)과 시간 부담, 가중치와 RRF 조정은 여러 값을 실험해도 점수가 비슷해, 요청 분류에서 먼저 검증한 Jev(정답 77 → 81/98건) 채택.
  해결: 벤치마크상 한국어 의미 검색이 가장 좋은 BGE-M3와 정확한 용어를 잡는 BM25로 후보를 모으고 Jev가 최종 근거를 고르는 2단계 구조. 동일 후보와 블라인드 교차 채점으로 비교한 뒤 후보를 300개로 줄이고 병렬 4, 6, 8, 10을 비교해 정확도 차이 없이 가장 효율적인 8병렬로 조정. 이후 실제 평가셋에서 후보 수를 다시 비교해 200개로 조정.
  성과: 직접 작성하고 팀원과 검수한 질문 100개 × 3회에서 정답률 71.7% → 93.0%, 근거 적합성 70.0% → 95.4%. 일반 RAG 대비 오답 7.3% → 1.0%. 전체 응답 평균 5.5초(일반 RAG 4.3초).

사용자 정의 Agent Skill과 승인 기반 실행

반복 작업을 Skill로 저장해 재사용하고, AI가 만든 변경은 사용자가 승인한 뒤에만 반영되도록 설계했습니다.

- 사용자 정의 작업 지침(Skill)
  문제: 사용자마다 반복 작업이 달라 모두 기능으로 만들 수 없고, AI 편집안이 요청을 빠뜨린 채 전달돼 같은 결과를 원하는 작업을 운에 맡기게 됨
  판단: 지침은 AI, 권한과 실행 범위 검사는 코드, 게시와 실제 반영은 사용자가 맡도록 책임 분리. 코드의 형식 검사만으로는 요청 누락을 못 잡아 LLM 의미 평가를 추가
  해결: 자연어 지침 작성, 검토, 게시와 권한 및 승인 우회 검사, 미리보기 후 별도 승인. 편집 결과는 의미 평가 후 최대 1회 재작성. 생성, 평가, 재작성은 단계별로 추적하도록 LangGraph 노드로 나누고, 게시한 Skill은 PostgreSQL에 불변 버전으로 저장
  성과: 직접 작성하고 팀원과 검수한 요청 30건 × 3회에서 편집 성공 77 → 80/90건(85.6% → 88.9%). 승인 전에는 문서가 바뀌지 않음을 확인

PDF → Markdown 본문 96.1%, 표 셀 99.3% 복원

사용자가 올린 PDF를 검색과 답변에 쓸 수 있도록, 표와 수식까지 보존해 Markdown으로 변환했습니다.

- PDF → Markdown 변환
  문제: 논문 PDF의 표와 수식이 깨지면 Wiki와 답변의 근거가 되는 수치를 쓸 수 없음
  판단: 깨진 곳만 고치는 방식은 탐지가 오류를 놓쳤고, 전체 AI 변환은 표 및 수식 정확도와 비용이 부족해 내용 유형별 처리로 전환. 본문은 추출이 빠른 AnyDoc, 복원은 GPU 운영비가 드는 sLLM 대신 상용 LLM API
  해결: 본문은 AnyDoc으로 추출해 깨진 부분만 AI로 보완, 표와 수식은 원본 영역을 따로 판독, 그림은 원본 보존
  성과: 도입 실험(PDF 4개)에서 복원율을 기존 Docling만 사용 시 약 45%에서 약 90%로 개선. 유형별 PDF 15개 × 3회 평가에서 제목 97.6%, 본문 96.1%, 표 셀 99.3%, 수식 100%, 이미지 91.3% 복원(AI 판정)

MSA: 기능별로만 나누면 DB 부하는 그대로이고 서비스 간 호출만 늘어난다고 보고 데이터 소유권 기준 분리를 제안, 팀원 및 멘토와 경계와 통신 방식을 공동 설계.

수치는 모두 내부 평가 기준입니다.

문제 해결 과정과 실험 결과는 상세 포트폴리오에서 볼 수 있습니다.

RAG 근거 선택 ↗ 에이전트 실행 환경 ↗ PDF 변환 ↗

Pilltip

2025.03 — 2025.12

개인 맞춤 AI 안심 복약 솔루션 | 부산대학교 졸업과제
팀 프로젝트 (3명 + 디자이너) / 핵심 백엔드, 데이터 정제

시작 계기: 약품 정보가 흩어져 있어, 지금 건강 상태에서 특정 약을 먹어도 되는지 확인하기 어렵다는 문제에서 출발했습니다.
팀 구성: 본인(백엔드와 AI), Android 1명(Kotlin 앱 전반), 백엔드와 보안 1명(사용자 DB, 로그인, 문진표, AES-GCM), 디자이너.
사용 언어: 백엔드와 챗봇 Java(Spring Boot, Spring AI), 의약품 데이터 정제 Python
아래 목록은 제가 구현한 기능입니다.

GitHub 저장소 ↗

데이터 정제 파이프라인 구축

약 4만 4천 건의 의약품 원문을 쉬운 설명으로 바꾸는 작업입니다. 같은 문장은 한 번만 변환해 약품별로 재사용했습니다.

- **문제:** 약 4만 4천 건을 그대로 쉬운 설명으로 바꾸면 API 비용이 약 $200으로, 예산 안에서 모든 약의 설명을 제공할 수 없었음.
  판단: 약 수를 줄이는 대신 같은 문장은 한 번만 변환. 실시간 응답이 필요 없는 작업이라 Batch API로 대기 시간을 받아들이고 비용을 낮춤.
  해결: 문장 블록으로 나눠 완전 일치 문장을 통합하고 GPT Batch API로 변환한 뒤 약품별로 재연결. 2026년 코어 병렬 처리와 확장이 가능한 PySpark로 재현해 단계별 효과 측정.
  성과: 전체 원문 변환 예상 비용 약 $200 대비 실제 API 지출 $11.18. 재현 실험에서 완전 일치 중복 제거로 텍스트 744MB → 44.1MB(−94.1%).

비용은 예상치와 실지출의 비교이며 전처리 인건비는 제외했습니다.

개인 건강 정보 기반 답변 제공 AI 복약 챗봇 개발

사용자가 증상을 자연어로 물으면 관련 약품과 복약 정보를 찾는 기능입니다. 건강 프로필은 내부에서 판단해 개인화에 활용하고, 외부 AI에 보내는 정보와 분리했습니다.

- **문제:** 약을 먹어도 되는지 확인하려는 사용자의 증상 표현과 약 효능 용어가 달라 검색이 어렵고, 개인화에 필요한 건강 정보는 외부 AI로 보낼 수 없었음.
  판단: 동의어 사전은 증상이 많고 서로 겹쳐 의미 검색으로, 프로필 필터링은 걸러야 할 경우가 너무 많아 내부 판단으로 전환. 벡터 DB는 Milvus보다 가벼운 Weaviate, 오케스트레이션은 백엔드가 Spring이라 별도 Python 컨테이너 부하를 피해 Spring AI 사용.
  해결: Weaviate 의미 검색과 AI 오케스트레이션으로 약품 탐색, 복약 위험, 섭취량별 처리 경로 구성. 임신 여부, 복용약, 기저질환은 내부 코드로 판단.
  성과: 자연어 증상으로 약품 정보를 탐색하고, 해당 건강 프로필을 외부 LLM 입력에서 제외한 개인화 흐름 구현.

문제 해결 과정과 실험 결과는 상세 포트폴리오에서 볼 수 있습니다.

데이터 파이프라인 사례 ↗ 개인화 설계 사례 ↗

기술

AI & Search	LangChain, LangGraph, Spring AI, RAG LangSmith, LLM Evaluation, LLM Guardrail
Backend	Java, Spring Boot, Python
Data & Infra	MySQL, PostgreSQL, Redis, Elasticsearch, Weaviate Docker, Docker Compose, GitHub Actions, Kafka

활동과 기여

2026.06 — 2026.06

Rhwp 오픈소스 기여

Claude Code에 작업 계획과 기여 규칙을 주고 이슈 분석부터 PR까지 자동화해, HWP/HWPX 저장 오류 수정 등 PR 7건 병합. Contributor로 등재됐습니다.

GitHub 저장소 ↗ PR #1213 | 병합 ↗ PR #1351 | 제출 ↗

2025.03 — 2026.01



부산대학교 APPTIVE

Backend 멘티 및 멘토. 멘티 12명 대상 6회 멘토링과 코드 리뷰. HTTP, Servlet, REST API, DB 기초를 보강하는 커리큘럼 개편에 참여했습니다.

APPTIVE 백엔드 멘토 공로상 | 2026.01.09

2025.11 / 2025.07



SK AI SUMMIT, K-ICT WEEK in Busan

부산대학교 대표 전시팀으로 Pilltip 부스를 운영하며 방문자 100명 이상에게 시연하고 기술 질의응답을 진행했습니다. 받은 피드백 10건 중 대부분이 건강기능식품 확장 요청이었습니다.

2022.02 — 2025.07



백준 945일 연속 문제 해결

하루 한 문제를 목표로 solved.ac 기준 최장 945일 연속 문제를 해결했습니다. 누적 1,659문제, solved.ac Platinum IV. 풀이는 GitHub 저장소에 기록했습니다.

BaekJoon 풀이 저장소 ↗

학력과 자격

2022.02 — 2026.02 (편입) **부산대학교**

평균 학점 4.12 / 4.5

2019.03 — 2022.02 (중퇴) **대구대학교**

평균 학점 4.2 / 4.5

2025.09 **정보처리기사**

한국산업인력공단

수상

2025.10 

캡스톤디자인 금상

소프트웨어와 인공지능 분과 / 부산대학교 정보의생명공학대학

2025.09 

부산 DATA WEEK 최우수상

데이터 활용 우수사례 공모전 / 부산테크노파크

2025.09 

AI LAUNCH 커리어스쿨 창업톤 장려상

KRYPTON X x Root Impact x Google.org

2025.08 

SW중심대학 디지털 경진대회 후원기업상

SW중심대학협의회