

SUMMARY

RAG 근거 선택: 근거 충족률 66.25% → 91.25%, 잘못된 근거 20 → 0건

에이전트 실행 환경: 사용자 정의 Skill과 승인 기반 실행, 편집 품질 82.5% → 91.2%(114건 평가)

데이터 파이프라인: PDF 변환 통과율 45.17% → 89.89%, 약품 변환 비용 예상 \$200 대비 \$11.18

PROJECTS & EXPERIENCE

Fruition

2026.04 — 현재

LLM Wiki 기반 AI 워크스페이스 · AI SW 마에스트로 17기 · AWS EKS 배포 완료, QA 진행 중
팀 프로젝트 (3명 + 디자이너) / AI 파트 리더

시작 계기: 팀원이 제기한 문서 관리의 불편함을 디자인 싱킹으로 구체화. 저장만 해 둔 문서를 필요할 때 찾기 못하는 문제를 풀고자 했습니다.
팀 구성: 본인(AI 전체), 백엔드 1명(Spring 백엔드 전체), 프론트엔드·DevOps 1명(프론트엔드, MSA 기반 AWS 배포), 외주 디자이너 · 멘토 3명

GitHub · AI 분리 저장소 ↗

RAG 과정의 검색 정확도 개선

저장된 문서에서 AI 답변에 필요한 근거를 찾고, 답이 없는 질문에는 근거를 붙이지 않게 하는 기능입니다.

- 답변 근거 선택 개선

문제: 기존 검색이 필요한 근거를 놓치고, 답이 없는 질문에도 근거를 반환.

해결: 라우팅에서 효과를 본 Jev(정해진 선택지 중에서만 답을 고르는 판단 전용 모델)를 RAG에 적용. 전체 근거 실행 후 동일 후보·반환량으로 비교 조건을 맞추고, 후보 300개·최대 4병렬로 조정.

판단: GPT는 비용·시간 부담, 가중치·RRF 조정은 실험해도 점수가 비슷해 Jev 채택.

성과: 논문 9편의 평가에서 답이 있는 80문항의 근거 충족률 66.25% → 91.25%. 답 없는 20문항의 잘못된 근거 반환 20 → 0건. Jev 최적화 전후 시간 중앙값 9.090초 → 2.251초(기존 0.431초보다 느림).

에이전트 실행 환경 - Skill·승인·라우팅과 대화 맥락

반복 작업을 Skill로 저장·재사용하고 실제 변경은 사용자 승인 후 반영하도록 설계했습니다. 요청 분류에는 Jev를 적용했고, 모델에 보낼 대화 맥락과 편집 입력의 범위도 함께 정했습니다.

- 사용자 정의 작업 지침(Skill)

문제: 사용자마다 다른 반복 작업을 개발자가 모두 기능으로 추가하기 어려움.

해결: 자연어 지침의 작성·검토·게시 기능과 권한·승인 유효 검사를 설계하고 AI 코딩 도구로 구현. 실제 문서 변경은 미리보기를 확인한 뒤 별도로 승인하도록 설계.

성과: 게시한 Skill을 Agent에서 사용할 수 있도록 연결. 문서 6개 검증에서 승인 전 변경 없이, 승인 후 폴더 3개 생성과 문서 이동 확인.

- Jev 기반 요청 분류 개선

문제: 사용자 질문을 문서 편집으로 분류하는 등 잘못된 작업으로 연결.

해결: 질문·편집·문서 생성·폴더 정리 등 작업 종류와 부가 조건을 고르는 라우팅에 Jev 적용.

판단: 출시 직후 모델이라 위험이 작은 요청 분류에서 먼저 검증.

성과: 동일 요청 98개에서 작업 종류와 부가 조건을 모두 맞춘 수 77 → 81건(같은 선택지를 준 GPT-5-nano 63건). 판단시간 중앙값 8.967초 → 0.658초.

- 대화 메모리

문제: 대화가 길어지면 이전 턴을 전부 모델에 넣을 수 없음.

해결: 최근 여섯 턴은 원문, 그 이전은 누적 요약으로 압축하고 요약 호출 실패 시 이전 요약을 유지. 라우터에 이전 턴의 라우팅 결정까지 전달해 지시어가 가리키는 대상을 해소.

- 편집 입력 범위 제한

문제: 문서 전체를 모델에 보내면 비용과 지연이 커짐.

해결: 대상 줄 범위와 주변 문맥만 전달하고 표·코드 블록 경계를 걸치는 범위는 거절. 원문 대비 입력 비율과 처리 시간 평균·p95를 벤치마크로 확인.

실행 신뢰성과 LLM 추적

AI가 이미 저장한 변경을 되돌리고, 실행 과정을 단계 단위로 확인할 수 있게 하는 작업입니다. 여러 저장소에 걸친 실행을 하나의 트랜잭션으로 묶을 수 없어 역작업으로 복구했습니다.

- 최소한 작업의 역순 복구

문제: AI 작업이 모델 호출 사이에 문서·폴더·Wiki·Skill을 여러 번 저장해, 실행만 멈추면 일부 변경이 남음.

해결: 취소 상태를 먼저 저장해 후속 쓰기를 막고, 변경 전 snapshot과 승인에 연결된 역등기로 자식부터 역순 복구. 복구는 모델 호출 없이 실행 기록만 쓰고, 전체 복구를 확인해야 취소가 확정.

- 다른 작업의 기여를 지우지 않는 복구

문제: 개념 페이지가 여러 문서의 기여를 합친 결과라, 과거 snapshot으로 덮으면 다른 문서의 정상 기여까지 사라짐.

해결: 작업·revision·문서별 기여를 덧붙이기만 하는 이력으로 남기고 복구 시 대상 기여만 제외해 재조립. 물리 삭제 대신 삭제 표시로 감사 이력 보존.

- LLM 실행 추적과 민감정보 경계

문제: 평가 루프가 일반 Python 흐름이라 단계별로 볼 수 없고, 추적에 보내는 내용에 민감정보가 섞일 수 있었음.

해결: 평가 루프를 LangGraph 그래프로 재구성해 생성-평가-재시도를 노드 단위로 추적. Agent 그래프는 추적을 끄고 도구 조회 원문을 상태 저장에서 제외하며, 자체 프롬프트 로그는 기록 전 숫자 개인정보를 마스킹. 시간을 재는 실험은 추적과 로그를 모두 끄고 실행.

문서 확장자 변환 파이프라인 구축과 Wiki 생성 시간 개선

사용자가 올린 PDF를 검색과 답변에 활용하도록 변환하고, 여러 문서의 Wiki 생성 시간을 줄였습니다.

- PDF → Markdown 변환

문제: 오픈소스 변환에서 표·수식이 손상됐고, 전체 AI 변환에도 오류와 호출 부담이 남음.

해결: PDF 변환 오픈소스를 비교해 AnyDoc 채택. 깨진 본문만 AI로 복원. 표·수식은 별도 처리하고 그림은 원본 보존.

판단: 본문은 빠른 AnyDoc으로 추출, GPU 운영비를 피해 복원은 sLLM 대신 상용 API로 전환.

성과: PDF 30쪽의 내부 평가 통과율 45.17% → 89.89%.

- 문서의 Wiki 생성 병렬화

문제: 앞선 문서의 외부 AI 응답을 기다리는 동안 뒤의 문서 처리가 지연.

해결: Worker 수와 내부 동시 요청 수를 각각 변경하며 비교. 메모리 증가를 고려해 Worker 최대 4개를 채택하고, 오히려 느려진 추가 동시 요청, GPU 병렬화는 제외.

성과: 문서 4개 분석 시간 282.11초 → 73.89초(약 74% 감소)

MSA: 기능별로만 나누면 DB 부하는 그대로이고 서비스 간 호출만 늘어난다고 보고 데이터 소유권 기준 분리를 제안, 팀원-멘토와 경계-통신 방식을 공동 설계.

수치는 내부 평가 기준이며, RAG 시간 단축은 Jev 최적화 전후 비교입니다. 문서 병렬 처리 시간은 저장·후처리를 제외한 분석 단계 기준입니다.

문제 해결 과정과 실험 결과는 상세 포트폴리오에서 볼 수 있습니다.

[RAG 근거 선택](#) [에이전트 실행 환경](#) [PDF 변환](#) [문서 병렬 처리](#)

Pilltip

2025.03 — 2025.12

개인 맞춤 AI 안심 복약 솔루션 · 부산대학교 졸업과제 · APK 내부 배포 사용자 6명

팀 프로젝트 (3명 + 디자이너) / 핵심 백엔드 · 데이터 정제

시작 계기: 약품 정보가 흩어져 있어, 지금 건강 상태에서 특정 약을 먹어도 되는지 확인하기 어렵다는 문제에서 출발했습니다.

팀 구성: 본인(백엔드-AI), Android 1명(Kotlin 앱 전반), 백엔드·보안 1명(사용자 DB, 로그인, 문진표, AES-GCM), 디자이너. 아래 목록은 제가 구현한 기능입니다.

[GitHub 저장소](#)

데이터 정제 파이프라인 구축

약 4만 4천 건의 의약품 원문을 쉬운 설명으로 바꾸는 작업입니다. 같은 문장은 한 번만 변환해 약품별로 재사용했습니다.

- **문제:** 약 4만 4천 건의 약품 원문을 모두 쉬운 설명으로 변환하면 API 비용 약 \$200 예상.

해결: 문장 블록으로 나눠 완전 일치 문장을 통합하고, GPT Batch API로 변환한 뒤 약품별로 재연결. 2026년 PySpark로 재현해 어미 통일·MinHashLSH 효과 측정.

판단: 실시간 응답이 필요 없는 작업이라 Batch API로 대기 시간을 받아들이고 비용을 낮춤.

성과: 전체 원문 변환 예상 비용 약 \$200 대비 실제 API 지출 \$11.18. 재현 실험에서 완전 일치 중복 제거로 텍스트 744MB → 44.1MB(-94.1%).

비용은 예상치와 실제출의 비교이며 전처리 인건비는 제외했습니다.

개인 건강 정보 기반 답변 제공 AI 복약 챗봇 개발

사용자가 증상을 자연어로 물으면 관련 약품과 복약 정보를 찾는 기능입니다. 건강 프로파일은 내부에서 판단해 개인화에 활용하고, 외부 AI에 보내는 정보와 분리했습니다.

- **문제:** 일상적인 증상 표현과 약품 효능의 용어가 다르고, 개인화에 필요한 건강 정보는 외부 AI에 전달하기 어려움.

해결: Weaviate 의미 검색과 AI 오케스트레이션으로 약품 탐색·복약 위험·섭취량별 처리 경로 구성. 임신 여부·복용약·기저질환은 내부 코드로 판단.

판단: 프로필을 필터링해 보내는 방식은 걸러야 할 경우가 너무 많아, 아예 외부 입력에서 빼고 내부에서 판단.

성과: 자연어 증상으로 약품 정보를 탐색하고, 해당 건강 프로필을 외부 LLM 입력에서 제외한 개인화 흐름 구현.

백엔드 기능 구현

앱에서 약품을 찾고 복약 위험정보를 확인하며, 복약 알람·기록과 가족 프로필을 사용할 수 있도록 서버 기능을 구현했습니다. 모바일 앱과 사용자·보안 기능을 맡은 팀원과 연동했습니다.

- Java-Spring Boot 기반 의약품 DB 설계, 검색·자동완성과 복약 위험정보(DUR) 표출 구현. Elasticsearch·Redis로 검색 응답 5~7초 → 평균 0.8초.

- FCM 복약 알람·로그, 딥링크 친구 초대, 가족 프로필 전환을 구현하고, Notion에 API 문서·회의록·ADR을 남겨 의사결정을 공유했습니다.

전시 현장 피드백을 반영한 기능 확장

부산대학교 대표 전시팀으로 두 차례 부스를 운영하며 방문자 100명 이상에게 시연하고 피드백 10건을 받았습니다. 대부분이 건강기능식품 요청이어서 보유한 데이터 범위에서 기능으로 연결했습니다.

- 건강기능식품 지원 확대

문제: 첫 전시에서 의약품만 확인할 수 있어, 건강기능식품도 함께 보고 싶다는 요청을 받음.

해결: 보유한 건강기능식품 데이터 범위에서 검색·자동완성 대상에 추가하고, 복용 주의·병용 정보 표출, 복약 알람·기록 등록, 챗봇 답변 대상까지 확장.

성과: 전시에서 받은 요청을 다음 개발 범위로 연결. 확보한 데이터에 한정되며 의약품과 같은 전수 정보는 아님.

- 반영하지 못한 지적

실행 환경을 컨테이너로 옮기는 편이 낫다는 지적을 받았지만 졸업과제 기간 내에는 적용하지 못했습니다. 이후 Fruition에서는 컨테이너 기반 배포를 전제로 AI 서비스를 나눴습니다.

문제 해결 과정과 실험 결과는 상세 포트폴리오에서 볼 수 있습니다.

[데이터 파이프라인 사례](#) [개인화 설계 사례](#)

기술

AI & Search	LangChain · LangGraph · Spring AI · RAG · LLM Evaluation · Prompt Injection 대응 LangSmith · Elasticsearch · Weaviate
Backend	Java · Spring Boot · Python
Data & Infra	MySQL · PostgreSQL · Redis · Kafka Docker · Docker Compose · GitHub Actions

활동 · 기여

2026.07 — 2026.09	200 SIGNAL · TQQQ 200일선 신호 앱 (개인 프로젝트) 커뮤니티의 TQQQ 200일선 매매법을 전략 명세로 구조화하고, 실시간 시세로 신호를 알리는 Android 앱으로 만들어 가족 2명이 사용했습니다. 원문이 주장한 성과는 미검증으로 표시하고, 45개 사이클을 재현해 승률이 19%가 아닌 40.00%임을 확인했습니다. 부분익절을 거래로 세면 승률이 72.73%로 오르는 것을 보여, 원문의 두 승률이 서로 다른 단위를 센다는 점까지 밝혔습니다. 전략 변형 5종도 같은 가정으로 백테스트해 CAGR-MDD를 구간별로 비교했습니다. 사용자 요청으로 QQQ 기반 두 번째 전략과 대기 자금의 SGOV-SPYM 운용을 추가했습니다. 앱은 배포하지 않았고, 계좌 정보는 기기 안에만 저장합니다. GitHub 저장소
2026.06 — 2026.06	Rhwp 오픈소스 기여 Claude Code에 작업 계획과 기여 규칙을 주고 이슈 분석부터 PR까지 자동화해, HWP/HWPX 저장 오류 수정 등 PR 7건 병합·Contributor로 등재됐습니다. GitHub 저장소 PR #1213 · 병합 PR #1351 · 제출
2025.03 — 2026.01	부산대학교 APPTIVE Backend 멘티 및 멘토. 멘티 12명 대상 6회 멘토링과 코드 리뷰. HTTP-Servlet-REST API-DB 기초를 보강하는 커리큘럼 개편에 참여했습니다. APPTIVE 백엔드 멘토 공로상 · 2026.01.09
2025.11 / 2025.07	SK AI SUMMIT · K-ICT WEEK in Busan 부산대학교 대표 전시팀으로 Plltip 부스를 운영하며 방문자 100명 이상에게 시연하고 기술 질의응답을 진행했습니다. 받은 피드백 10건 중 대부분이 건강기능식품 확장 요청이었습니다.
2022.02 — 2025.07	백준 945일 연속 문제 해결 solved.ac 기준 최장 945일 연속. 누적 1,659문제, Platinum IV. BaekJoon 풀이 저장소

학력 · 자격

2022.02 — 2026.02 (편입)	부산대학교 평균 학점 4.12 / 4.5
2019.03 — 2022.02 (중퇴)	대구대학교 평균 학점 4.2 / 4.5
2025.09	정보처리기사 한국산업인력공단

수상

2025.10	 캡스톤디자인 금상 소프트웨어·인공지능 분과 / 부산대학교 정보의생명공학대학
2025.09	 부산 DATA WEEK 최우수상 데이터 활용 우수사례 공모전 / 부산테크노파크
2025.09	 AI LAUNCH 커리어스쿨 창업톤 장려상 KRYPTON X x Root Impact x Google.org
2025.08	 SW중심대학 디지털 경진대회 후원기업상 SW중심대학협의회